


UNIVERSITÀ DEGLI STUDI DI MODENA E REGGIO EMILIA



Tecniche di Quantizzazione Avanzate per Modelli Linguistici di Grandi Dimensioni


Analisi Teorica e Valutazione Sperimentale su Supercomputer Leonardo

Candidata: Ester Vecchio (Matr. 187790)

Corso di Laurea: Triennale in Ingegneria Informatica (MO)

Relatore: Chiar.mo Prof. Lorenzo Baraldi

Anno Accademico 2025/2026



Introduzione e Obiettivi di Ricerca

I principali vincoli degli LLM

I modelli LLM recenti superano regolarmente decine di miliardi di parametri, le cui conseguenze sono:

- **Memory-wall**
 - L'occupazione intensa VRAM, impone l'uso del calcolo distribuito.
 - Inference Bottleneck, a causa dei continui trasferimenti HBM → SRAM
- **Costi Computazionali ed Energetici**
- **Deployment su Sistemi Embedded ed Edge**

Obiettivo della Tesi


Validare e confrontare metodologie di **quantizzazione** ad alta efficienza per abbattere il footprint di memoria senza degradare eccessivamente le prestazioni semantiche.

1. **Formalizzazione teorica:** PTQ (Min-Max, GPTQ, SmoothQuant) e QAT (STE, LoRA/QLoRA)
2. **Validazione su Leonardo:** pipeline di benchmark offline su GPU NVIDIA A100 (64GB) presso CINECA

LLM e il Principio della Quantizzazione

Un **Large Language Model** è una rete neurale basata su architettura Transformer, addestrata su enormi corpora testuali per generare testo in modo autoregressivo, un token alla volta, condizionando ogni predizione sul contesto precedente.

La **quantizzazione** riduce la risoluzione dei pesi e/o delle attivazioni da rappresentazioni ad alta precisione a formati discreti a bassa precisione



Riduzione della precisione

BF16 / FP16



INT8



INT4



Ternario (BitNet)



Due strategie per applicarla: quando intervenire nel ciclo di vita del modello

POST-TRAINING

PTQ

Applicata dopo l'addestramento, senza retraining: rapida ma può degradare l'accuratezza.

FINE-TUNING

QAT


Simulata durante un fine-tuning adattivo: più costosa, ma recupera meglio la qualità persa.

Granularità: i 3 tipi

1

Per-Tensor


Un unico fattore di scala per l'intera matrice dei pesi. Minimo overhead di metadati, ma alta sensibilità agli outlier di attivazione.



2

Per-Channel


Un fattore di scala dedicato per ciascun canale di output (riga). Isolamento parziale delle variazioni di ampiezza dei parametri.



3

Block-wise (G=4)

I pesi sono suddivisi in blocchi contigui di G elementi. Mantiene un'elevata precisione locale isolando efficacemente gli outlier repentini.



Nei test: tutte le configurazioni sperimentali (Min-Max, GPTQ, QAT) adottano la granularità Block-wise con $G=128$, lo standard di riferimento per l'inferenza INT4 su GPU moderne.

Calibrazione: le Tecniche Messe alla Prova


Come si determina il fattore di scala che converte i pesi in interi a 4-bit — le due tecniche confrontate nei test sperimentali

STATICA — RANGE COMPLETO

Min-Max Simmetrica

Fissa il fattore di scala sull'intero intervallo [min, max] dei pesi osservati nel tensore. Non richiede un dataset di calibrazione dedicato: è immediata da applicare.

Effetto nei test: massima velocità (kernel leggeri, throughput più alto) ma alta sensibilità agli outlier
→ perplexity più degradata rispetto a BF16.



DATA-DRIVEN — 2° ORDINE

GPTQ (Basata su Hessiana)

Utilizza un piccolo dataset di calibrazione per stimare l'inversa della matrice Hessiana dell'errore e aggiorna i pesi rimanenti colonna per colonna, compensando l'errore di quantizzazione.

Effetto nei test: migliore fedeltà linguistica (perplexity più bassa) ma il backend dedicato, non fuso con torch.compile, introduce overhead
→ throughput inferiore.

Infrastruttura sperimentale:

Welcome to:

Leonardo

1

Hardware HPC

Partizione Leonardo Booster (CINECA Tier-0). Nodo di calcolo equipaggiato con GPU NVIDIA Custom A100 SXM4 da 64GB VRAM, interconnessione NVLink ad alta banda.

2

Software Stack

Framework PyTorch 2.x unitamente alla libreria nativa torchao (PyTorch Architecture Optimization) per i formati e i kernel quantizzati INT4/INT8, e PEFT per il fine-tuning LoRA.

3

Ottimizzazione JIT

Compilazione JIT dei grafi computazionali tramite torch.compile (backend Inductor) per la fusione automatica dei kernel CUDA e l'eliminazione dei colli di bottiglia.

Metodologia dei test

Modelli oggetto di studio: Meta-Llama-3.1-8B e Google Gemma-2-9B, rappresentativi dello stato dell'arte nella fascia 8-9 miliardi di parametri.

TTFT

Time-To-First-Token (ms):
latenza della fase di Prefill —
reattività percepita

Throughput

Velocità in token/s durante la
fase di Decode autoregressivo

Picco VRAM

Monitoraggio della memoria
video massima riservata su GPU
A100

Perplexity

Misura quanto è “sorpreso” il
modello quando lavora sui dati
dei test

Quindi valuta la degradazione
linguistica su WikiText-2
(dominio del dataset per i test)

Risultati: Meta-Llama-3.1-8B

Prestazioni di inferenza registrate su GPU NVIDIA A100 (64GB) — Supercomputer Leonardo

Configurazione	Precisione	VRAM Peak	TTFT	Throughput	Perplexity
Baseline BF16	BF16 (16-bit)	15.17 GiB	19 ms	69.91 tok/s	10.32
PTQ Min-Max + torch.compile	INT4 (Group 128)	4.92 GiB (3.08×)	77 ms	106.10 tok/s	12.55
PTQ GPTQ (backend standard)	INT4 (Group 128)	5.66 GiB (2.68×)	34 ms	32.16 tok/s	12.10

Insight: la quantizzazione PTQ Min-Max con kernel fusi torchao + torch.compile abbatte la VRAM di oltre 3× e aumenta il throughput del 52% rispetto a BF16. GPTQ, eseguito su backend non fuso allo stesso modo, risulta più lento della baseline pur mantenendo un TTFT contenuto.

Risultati: Google Gemma-2-9B

Prestazioni di inferenza registrate su GPU NVIDIA A100 (64GB) — Supercomputer Leonardo

Configurazione	Precisione	VRAM Peak	TTFT	Throughput	Perplexity
Baseline BF16	BF16 (16-bit)	17.69 GiB	23 ms	61.08 tok/s	14.31
PTQ Min-Max + torch.compile	INT4 (Group 128)	7.24 GiB (2.44×)	104 ms	75.42 tok/s	15.75
PTQ GPTQ (backend standard)	INT4 (Group 128)	6.30 GiB (2.81×)	43 ms	29.36 tok/s	14.76
QAT LoRA (non allineato)	INT4 (Group 128)	7.24 GiB (2.44×)	104 ms	77.91 tok/s	15.76
QAT LoRA (allineato, WikiText-2)	INT4 (Group 128)	7.24 GiB (2.44×)	104 ms	66.01 tok/s	9.09
QAT LoRA (allineato, C4)	INT4 (Group 128)	7.24 GiB (2.44×)	104 ms	72.65 tok/s	12.99

Insight: l'architettura di Gemma-2 (sliding window attention e logit capping) beneficia sensibilmente del recupero di qualità garantito dal QAT: addestrato su WikiText-2 supera persino la baseline BF16, un effetto in parte dovuto ad adattamento di dominio, confermato dalla validazione out-of-domain su C4.

Analisi Critica delle Prestazioni

3.08×

Compressione massima della memoria
VRAM (Llama-3-8B, Min-Max)

+52%

Incremento di throughput rispetto a
BF16 (Llama-3-8B, Min-Max)



−9%

Perplexity: beneficio genuino del QAT,
validato out-of-domain su C4

Superamento del Memory Wall

Importanza della Fusione dei Kernel

Valore del dominio nel fine-tuning



Conclusioni

1

Guadagni prestazionali reali, ma condizionati

La quantizzazione riduce drasticamente l'impronta di memoria e la latenza dell'inferenza, ma l'efficienza effettiva varia in base all'architettura del modello, al tipo di quantizzazione applicata, al backend hardware e al livello di accuratezza tollerato.

2

Dalla Forza Bruta all'Efficienza Algoritmica: Sovrarappresentazione e Cambio di Paradigma

Riconoscere la sovrarappresentazione e la ridondanza parametrica dei modelli permette di superare la logica della forza bruta, dimostrando come l'efficienza algoritmica possa preservare la capacità informativa riducendo al minimo lo spreco computazionale

3

Sostenibilità Ecologica ed Efficienza Energetica (Green AI)

Ridurre il consumo di memoria e calcolo abbatte direttamente la domanda energetica dell'inferenza su larga scala, trasformando l'ottimizzazione dei modelli in una leva fondamentale di sostenibilità ambientale.

4

Democratizzazione dell'Intelligenza Artificiale ed Equità Sociale

Rendere eseguibili modelli complessi su hardware meno energivori o di fascia medio-bassa riduce il divario tecnologico, permettendo a startup, ricercatori e Paesi in via di sviluppo di accedere all'IA avanzata senza costi infrastrutturali proibitivi.

5

Il Collo di Bottiglia Fisico ed Energetico dell'Hardware Convenzionale

L'ottimizzazione a 4 bit non altera la fisica dell'hardware: il trasferimento dati nel paradigma di Von Neumann e i consumi statici dei transistor inutilizzati impongono un limite invalicabile all'efficienza puramente software.

6

La Necessità dell'Interdisciplinarietà per il Superamento dei Limiti

Superare le attuali barriere tecnologiche richiede la convergenza tra informatica, fisica dei materiali, neuroscienze ed etica, abbandonando gli approcci a compartimenti stagni a favore di una co-progettazione interdisciplinare.

Grazie per l'attenzione!

La quantizzazione avanzata rappresenta il ponte fondamentale tra la teoria algoritmica degli LLM e la loro adozione efficiente, sostenibile e scalabile.

Ora lascio spazio a domande e chiarimenti...

Ester Vecchio — Relatore: Prof. Lorenzo Baraldi
Università degli Studi di Modena e Reggio Emilia

